

Clasificación de Residuos Sólidos mediante Redes Neuronales Convolucionales

Xiomara Pérez Alzate
Universidad de Antioquia
Medellín, Colombia
Correo: xiomara.perez@udea.edu.co

I. INTRODUCCIÓN

La creciente generación de residuos sólidos representa uno de los principales desafíos ambientales a nivel global. Una adecuada clasificación de los residuos permite optimizar los procesos de reciclaje, reducir la contaminación y mejorar la eficiencia en la gestión de desechos. Sin embargo, la clasificación manual resulta costosa, lenta y propensa a errores humanos.

En este contexto, el uso de técnicas de visión por computador basadas en Deep Learning, particularmente las redes neuronales convolucionales (CNN), permite automatizar la identificación y clasificación de residuos a partir de imágenes. Estas redes son capaces de aprender patrones visuales complejos como texturas, formas y colores, lo que las hace especialmente adecuadas para tareas de clasificación de imágenes.

II. DESCRIPCIÓN DEL PROBLEMA

A. Contexto de aplicación

La gestión ineficiente de residuos genera impactos negativos significativos en el medio ambiente, incluyendo contaminación del suelo, agua y aire. Uno de los principales retos en los sistemas de reciclaje es la correcta separación de los materiales, lo cual influye directamente en la reutilización y tratamiento de los mismos.

Actualmente, muchos procesos de clasificación siguen dependiendo de intervención humana, lo que introduce errores, incrementa los costos operativos y limita la escalabilidad de los sistemas. En este sentido, la automatización mediante modelos de inteligencia artificial permite mejorar significativamente la eficiencia y precisión del proceso.

Las soluciones basadas en clasificación de imágenes pueden implementarse en diversos escenarios:

- Plantas de reciclaje automatizadas
- Sistemas inteligentes de separación de residuos
- Dispositivos IoT para clasificación doméstica
- Aplicaciones móviles orientadas a la educación ambiental

B. Objetivo de Machine Learning

El objetivo principal es desarrollar un modelo de aprendizaje supervisado capaz de clasificar imágenes de residuos en múltiples categorías.

$$f(x) \rightarrow y$$

donde:

- x : imagen de entrada
- y : clase del residuo

Se trata de un problema de clasificación multiclase con 10 categorías.

C. Dataset

Se utiliza el dataset Garbage Classification de Kaggle, diseñado para sistemas de clasificación de residuos prácticos y escalables.

Características:

- Tipo de datos: Imágenes RGB
- Número de clases: 10
- Número total de imágenes: 8775
- Tamaño: 100–200 MB
- Resolución: Variable

Clases:

- Battery
- Biological
- Brown-glass
- Cardboard
- Green-glass
- Metal
- Paper
- Plastic
- Trash
- White-glass

D. Distribución de clases

TABLE I
DISTRIBUCIÓN DE CLASES

Clase	Imágenes
Plastic	1000
Brown-glass	666
Cardboard	1000
Metal	1000
Green-glass	666
Paper	1000
Battery	1000
Biological	1000
White-glass	777
Trash	666

El dataset presenta un desbalance moderado entre clases, lo cual refleja condiciones reales y contribuye a entrenar modelos más robustos.

E. Métricas de desempeño

Para evaluar el desempeño del modelo se utilizarán métricas tanto de Machine Learning como de impacto práctico. Dado que se trata de un problema de clasificación multiclase con un leve desbalance en algunas categorías, es necesario utilizar métricas que permitan un análisis más completo que la simple exactitud.

1) Métricas de Machine Learning:

- **Accuracy:** mide la proporción de predicciones correctas sobre el total de muestras evaluadas. Aunque es una métrica general útil, puede resultar engañosa en escenarios con desbalance de clases, ya que un modelo puede obtener alta exactitud favoreciendo las clases más frecuentes.
- **Precision:** mide la proporción de predicciones positivas correctas respecto al total de predicciones positivas realizadas por el modelo. Es especialmente importante cuando se busca minimizar falsos positivos.

$$Precision = \frac{TP}{TP + FP}$$

- **Recall (Sensibilidad):** mide la capacidad del modelo para identificar correctamente todas las instancias de una clase. Es relevante cuando se busca minimizar falsos negativos.

$$Recall = \frac{TP}{TP + FN}$$

- **F1-score:** es la media armónica entre precision y recall, proporcionando una medida balanceada del rendimiento del modelo, especialmente útil en problemas con desbalance de clases.

$$F1 = \frac{2 \cdot (Precision \cdot Recall)}{Precision + Recall} \quad (1)$$

Dado que el problema es multiclase, estas métricas se calcularán tanto de forma global como por clase individual, utilizando promedios como *macro-average* (promedio simple entre clases) y *weighted-average* (ponderado por número de muestras).

Además, se empleará la **matriz de confusión**, la cual permite visualizar el desempeño del modelo en cada clase y detectar errores frecuentes de clasificación entre categorías similares, como diferentes tipos de vidrio o materiales reciclables.

2) *Métricas de negocio:* Más allá del desempeño técnico del modelo, se consideran métricas orientadas al impacto práctico de la solución:

- **Reducción de errores en la clasificación:** disminución de la tasa de clasificación incorrecta en comparación con procesos manuales.
- **Mejora en la eficiencia del reciclaje:** incremento en la correcta separación de residuos, facilitando su reutilización.
- **Reducción de costos operativos:** menor dependencia de mano de obra humana en procesos de clasificación.

- **Escalabilidad del sistema:** capacidad de implementar el modelo en entornos reales como plantas de reciclaje o dispositivos inteligentes.

3) Métricas de negocio:

- Reducción de errores en clasificación
- Mejora en reciclaje
- Reducción de costos operativos
- Aplicación en sistemas reales

III. RESULTADOS ESPERADOS

Se espera que el modelo CNN logre alta precisión en la clasificación de residuos. El uso de transfer learning puede mejorar significativamente el desempeño.

IV. CONCLUSIONES

Se propone un sistema de clasificación automática de residuos utilizando CNN. El uso de un dataset con 10 clases permite abordar un problema más realista.

Las CNN permiten extraer características visuales complejas, mejorando la precisión frente a métodos tradicionales.

Este tipo de soluciones tiene alto potencial en aplicaciones reales, contribuyendo a la automatización del reciclaje y la sostenibilidad ambiental.

REFERENCIAS

- [1] Kaggle Dataset Garbage Classification
TensorFlow Documentation
Krizhevsky et al., 2012
He et al., 2016