

Clasificación de Residuos Sólidos mediante Redes Neuronales Convolucionales y Transfer Learning con EfficientNetBO

Xiomara Pérez Alzate
Universidad de Antioquia
Medellín, Colombia
Correo: xiomara.perez@udea.edu.co

I. CLASIFICACIÓN AUTOMÁTICA DE RESIDUOS SÓLIDOS MEDIANTE REDES NEURONALES CONVOLUCIONALES Y TRANSFER LEARNING

A. Resumen

La clasificación automática de residuos sólidos constituye un problema de gran relevancia dentro de los procesos modernos de gestión ambiental y reciclaje. La correcta separación de materiales permite optimizar el aprovechamiento de recursos, reducir la contaminación y mejorar la eficiencia de las cadenas de tratamiento de residuos. En este proyecto se desarrolló un sistema de clasificación de imágenes basado en técnicas de Deep Learning para identificar diez categorías diferentes de residuos.

Se implementaron dos enfoques principales. En primer lugar, una Red Neuronal Convolutiva (CNN) diseñada y entrenada desde cero, utilizada como línea base de comparación. Posteriormente, se desarrolló una solución basada en Transfer Learning utilizando EfficientNetB0 preentrenada sobre ImageNet, complementada con una etapa de Fine Tuning para adaptar el modelo al dominio específico del problema.


Los resultados obtenidos evidencian una mejora significativa al utilizar aprendizaje por transferencia. Mientras la CNN base alcanzó una exactitud de 68.03% y un F1-Score de 67.73%, la arquitectura basada en EfficientNetB0 logró una exactitud de 91.80% y un F1-Score de 91.76%, demostrando la efectividad de reutilizar conocimiento previamente aprendido para tareas de clasificación visual.

Palabras clave: Deep Learning, CNN, Transfer Learning, EfficientNet, Clasificación de Imágenes, Gestión de Residuos.

II. INTRODUCCIÓN

La creciente generación de residuos sólidos representa uno de los principales desafíos ambientales de la actualidad. La correcta clasificación de materiales reciclables permite mejorar los procesos de recuperación y reducir el impacto ambiental asociado a la disposición final de residuos.

Tradicionalmente, la clasificación se realiza de manera manual, lo que implica altos costos operativos, errores humanos y limitaciones de escalabilidad. Gracias a los avances recientes en Visión por Computador y Aprendizaje Profundo, es posible automatizar este proceso mediante sistemas capaces de identificar visualmente diferentes tipos de materiales.



Las Redes Neuronales Convolucionales han demostrado excelentes resultados en tareas de reconocimiento de imágenes debido a su capacidad para aprender automáticamente características relevantes a partir de los datos. Más recientemente, las técnicas de Transfer Learning han permitido reutilizar modelos entrenados sobre grandes volúmenes de información para resolver nuevos problemas con menor costo computacional y mejores niveles de precisión.

El objetivo principal de este proyecto consiste en desarrollar y comparar dos soluciones para la clasificación automática de residuos sólidos utilizando imágenes digitales.

III. DESCRIPCIÓN DEL DATASET

El conjunto de datos utilizado corresponde al dataset **Garbage Classification Dataset**, disponible públicamente en Kaggle.

El dataset contiene imágenes pertenecientes a diez categorías:

- Battery
- Biological
- Brown Glass
- Cardboard
- Green Glass
- Metal
- Paper
- Plastic
- Trash
- White Glass

La distribución de imágenes se presenta en la Figura 1.

A. Figura 1. Distribución de imágenes por categoría

La mayoría de las categorías contienen aproximada-



Fig. 1. Ejemplos de imágenes de cada clase

mente 1000 imágenes. Sin embargo, algunas clases presentan una menor cantidad de ejemplos, especialmente brown-glass, green-glass y trash.

Aunque existe cierto desbalance, la diferencia entre categorías no es extrema y permite entrenar modelos supervisados sin aplicar técnicas adicionales de balanceo.

Para el entrenamiento se realizó una partición estratificada:

- 70% entrenamiento
- 15% validación
- 15% prueba
-

La estratificación garantiza que todas las clases mantengan proporciones similares en cada subconjunto.

IV. ESTRUCTURA DE LOS NOTEBOOKS ENTREGADOS

El proyecto fue organizado mediante cuatro notebooks independientes.

A. Notebook 1 – Exploración y Análisis del Dataset

Este notebook se enfocó en el análisis exploratorio de los datos.

Actividades realizadas:

- Descarga del dataset.
- Construcción del DataFrame.
- Exploración de categorías.
- Conteo de imágenes por clase.
- Visualización de muestras.
- Análisis de distribución.
-

El objetivo principal fue comprender las características del conjunto de datos antes del diseño de los modelos.

B. Notebook 2 – Preprocesamiento

En este notebook se implementó el flujo de preparación de datos.

Actividades realizadas:

- División Train / Validation / Test.
- Codificación numérica de etiquetas.
- Construcción de pipelines TensorFlow.
- Redimensionamiento de imágenes.
- Creación de datasets optimizados mediante tf.data.

Este notebook constituye la base de entrada para los modelos posteriores.

	precision	recall	f1-score	support
battery	0.67	0.71	0.69	150
biological	0.81	0.73	0.77	150
brown-glass	0.84	0.76	0.80	100
cardboard	0.84	0.83	0.84	150
green-glass	0.85	0.85	0.85	100
metal	0.67	0.42	0.52	150
paper	0.57	0.87	0.69	150
plastic	0.54	0.60	0.57	150
trash	0.62	0.49	0.55	100
white-glass	0.53	0.52	0.52	117
accuracy			0.68	1317
macro avg	0.69	0.68	0.68	1317
weighted avg	0.69	0.68	0.68	1317

Fig. 2. Reporte de clasificación CNN




Fig. 3. Curvas Accuracy y Loss CNN

C. Notebook 3 – CNN Baseline

Se implementó una red neuronal convolucional diseñada desde cero para establecer una línea base de comparación.

La arquitectura utilizada incluye:

- Tres capas convolucionales.
- Batch Normalization.
- Max Pooling.
- Global Average Pooling.
- Capas densas totalmente conectadas.
- Dropout para reducir sobreajuste.

La figura 2 presenta el reporte de clasificación obtenido por la CNN Baseline sobre el conjunto de prueba. Los resultados muestran un desempeño global aceptable, alcanzando una precisión (Accuracy) de 68.03% y un F1-Score ponderado de 67.73%.

Las categorías con mejor desempeño fueron *green-glass* (F1 = 0.85), *cardboard* (F1 = 0.84) y *brown-glass* (F1 = 0.80), lo que indica que el modelo logró identificar correctamente materiales con características visuales distintivas. Asimismo, la clase *biological* alcanzó un F1-Score de 0.77, evidenciando una adecuada capacidad de discriminación.

Por otro lado, las categorías *metal* (F1 = 0.52), *white-glass* (F1 = 0.52), *trash* (F1 = 0.55) y *plastic* (F1 = 0.57) presentaron mayores dificultades de clasificación. Estas clases suelen compartir características visuales similares con otros residuos, lo que incrementa la probabilidad de confusión durante el proceso de predicción.

La figura 3 "Curvas Accuracy y Loss CNN" muestra la evolución de la exactitud y la función de pérdida durante el entrenamiento de la CNN propuesta como línea base. Se observa una tendencia creciente de la precisión tanto en entrenamiento

	precision	recall	f1-score	support
battery	0.95	0.95	0.95	150
biological	0.95	0.98	0.97	150
brown-glass	0.94	0.92	0.93	100
cardboard	0.95	0.95	0.95	150
green-glass	0.93	0.97	0.95	100
metal	0.87	0.91	0.89	150
paper	0.91	0.93	0.92	150
plastic	0.85	0.85	0.85	150
trash	0.94	0.93	0.93	100
white-glass	0.89	0.79	0.84	117
accuracy			0.92	1317
macro avg	0.92	0.92	0.92	1317
weighted avg	0.92	0.92	0.92	1317

Fig. 4. Reporte de clasificación Transfer Learning - EfficientNetB0

como en validación, alcanzando valores cercanos al 70 %. Asimismo, la pérdida disminuye progresivamente, indicando que el modelo logra aprender características relevantes del conjunto de imágenes.

Sin embargo, también se evidencian fluctuaciones importantes en la curva de validación, especialmente entre las épocas 7 y 10. Este comportamiento sugiere que la arquitectura presenta ciertas limitaciones para generalizar adecuadamente ante imágenes no vistas, lo que justifica la exploración posterior de técnicas de Transfer Learning.

En términos generales, los resultados obtenidos constituyen una línea base sólida para posteriores experimentos, aunque evidencian limitaciones inherentes al entrenamiento de una red convolucional desde cero sobre un conjunto de datos relativamente reducido.

D. Notebook 4 – Transfer Learning

Se implementó una solución basada en EfficientNetB0 preentrenada sobre ImageNet.

Las etapas principales fueron:

- Congelamiento de pesos.
- Entrenamiento de capas finales.
- Fine Tuning de las últimas capas.
- Evaluación comparativa frente a la CNN baseline.

La Figura 4 presenta el reporte de clasificación obtenido por el modelo basado en Transfer Learning utilizando EfficientNetB0 preentrenada sobre ImageNet. Los resultados evidencian una mejora sustancial respecto a la CNN Baseline, alcanzando una precisión global (Accuracy) de 91.80% y un F1-Score ponderado de 91.76%.

La mayoría de las categorías presentan valores superiores al 90% en precisión, recall y F1-Score, lo que indica una elevada capacidad de generalización del modelo. Las clases con mejor desempeño fueron *biological* (F1 = 0.97), *battery* (F1 = 0.95), *cardboard* (F1 = 0.95) y *green-glass* (F1 = 0.95), demostrando que EfficientNetB0 logró extraer características visuales altamente discriminativas para identificar correctamente los diferentes tipos de residuos.

Asimismo, categorías tradicionalmente complejas como *metal*, *paper* y *trash* experimentaron mejoras significativas respecto a la CNN entrenada desde cero. En particular, la clase *metal* incrementó su F1-Score desde 0.52 hasta 0.89, mientras




Fig. 5. Curvas de aprendizaje Transfer Learning

que *trash* pasó de 0.55 a 0.93, evidenciando el impacto positivo del conocimiento previamente aprendido durante el preentrenamiento en ImageNet.

Las clases con menor desempeño relativo fueron *plastic* (F1 = 0.85) y *white-glass* (F1 = 0.84). Aunque estas categorías continúan siendo las más difíciles de distinguir, los resultados siguen siendo considerablemente superiores a los obtenidos por la CNN Baseline. Estas dificultades pueden atribuirse a similitudes visuales entre materiales transparentes, reflejos, condiciones de iluminación y variaciones presentes en las imágenes del conjunto de datos.

La figura 5 muestra las curvas de aprendizaje obtenidas mediante Transfer Learning utilizando EfficientNetB0. En comparación con la CNN base, el proceso de convergencia es más estable y rápido. La diferencia entre entrenamiento y validación es reducida, indicando una mejor capacidad de generalización gracias al conocimiento previamente aprendido sobre ImageNet.

En términos generales, el reporte confirma que la estrategia de Transfer Learning permitió construir un clasificador robusto y capaz de identificar correctamente la mayoría de las categorías de residuos sólidos con un alto nivel de precisión.

V. METODOLOGÍA

A. 4.1 Preprocesamiento

Todas las imágenes fueron redimensionadas a una resolución de 224×224 píxeles.

Para el modelo basado en EfficientNetB0 se utilizó la función:

```
preprocess_input()
incluida dentro de TensorFlow.
```

Esta función adapta automáticamente los valores de los píxeles al rango esperado por el modelo preentrenado.

B. 4.2 Data Augmentation

Con el fin de mejorar la capacidad de generalización se aplicaron técnicas de aumento de datos:

- Rotación aleatoria.
- Zoom aleatorio.
- Volteo horizontal.

Estas transformaciones permiten generar nuevas variantes de las imágenes sin modificar sus etiquetas.

Métrica	Valor
Accuracy	0.6803
Precision	0.6904
Recall	0.6803
F1-Score	0.6773

Métrica	Valor
Accuracy	0.9180
Precision	0.9179
Recall	0.9180
F1-Score	0.9176

Métrica	CNN Baseline	EfficientNetB0
Accuracy	68.03%	91.80%
Precision	69.04%	91.79%
Recall	68.03%	91.80%
F1-Score	67.73%	91.76%

VI. MODELO BASELINE: CNN DESDE CERO

La CNN desarrollada posee la siguiente estructura:

- Conv2D (32 filtros)
- BatchNormalization
- MaxPooling
- Conv2D (64 filtros)
- BatchNormalization
- MaxPooling
- Conv2D (128 filtros)
- BatchNormalization
- MaxPooling
- GlobalAveragePooling
- Dense(128)
- Dropout(0.5)
- Dense(10)

La arquitectura fue diseñada para servir como referencia inicial antes de utilizar modelos más avanzados.

Durante el entrenamiento se empleó:

- Adam Optimizer
- Learning Rate inicial de 1e-3
- Early Stopping
- ReduceLROnPlateau

VII. MODELO TRANSFER LEARNING CON EFFICIENTNETB0

EfficientNetB0 es una arquitectura moderna optimizada mediante escalamiento compuesto de profundidad, ancho y resolución.

A diferencia de la CNN baseline, este modelo ya posee conocimiento adquirido durante el entrenamiento sobre millones de imágenes de ImageNet.

La estrategia utilizada fue:

A. Fase 1: Feature Extraction

- Congelar completamente EfficientNetB0.
- Entrenar únicamente las capas densas finales.

B. Fase 2: Fine Tuning

- Descongelar las últimas 30 capas.
- Continuar entrenamiento con learning rate reducido.

Este procedimiento permite adaptar gradualmente las características aprendidas al dominio específico de residuos sólidos.

VIII. RESULTADOS

A. 7.1 CNN Baseline

Resultados obtenidos:

Las clases cardboard, green-glass y brown-glass mostraron los mejores desempeños.

Las categorías plastic, trash y white-glass presentaron mayores dificultades debido a similitudes visuales con otras clases.

B. 7.2 Transfer Learning

Resultados obtenidos:

La mayoría de las categorías alcanzaron valores superiores al 90%.

Las clases biological, cardboard, battery y green-glass mostraron desempeños sobresalientes.

Incluso las categorías tradicionalmente complejas, como plastic y trash, presentaron mejoras significativas respecto a la CNN baseline.

IX. COMPARACIÓN DE MODELOS

La mejora absoluta en Accuracy fue superior a 23 puntos porcentuales.

Asimismo, el F1-Score aumentó aproximadamente 24 puntos porcentuales.

Estos resultados demuestran que el aprendizaje por transferencia permite obtener representaciones visuales mucho más robustas que una CNN entrenada desde cero sobre un conjunto de datos relativamente pequeño.

X. ITERACIONES REALIZADAS

Durante el desarrollo del proyecto se realizaron múltiples iteraciones.

Entre las principales mejoras implementadas se encuentran:

- Corrección del pipeline de lectura de imágenes.
- Ajuste de normalización para EfficientNet.
- Incorporación de Data Augmentation.
- Sustitución de Flatten por GlobalAveragePooling.
- Ajuste de Learning Rate.
- Inclusión de Early Stopping.
- Implementación de Fine Tuning.
- Optimización de hiperparámetros.

Cada una de estas modificaciones contribuyó progresivamente a mejorar la capacidad de generalización del modelo.

XI. CONCLUSIONES

La clasificación automática de residuos sólidos mediante Deep Learning demostró ser una solución efectiva para tareas de separación automatizada.

La CNN baseline permitió establecer una referencia inicial razonable, alcanzando un Accuracy cercano al 68%.

Sin embargo, la incorporación de Transfer Learning mediante EfficientNetB0 produjo una mejora sustancial, alcanzando aproximadamente 92% de Accuracy y F1-Score.

Los resultados evidencian que reutilizar conocimiento previamente aprendido constituye una estrategia altamente efectiva cuando se dispone de conjuntos de datos moderados.

Como trabajo futuro podrían explorarse arquitecturas más avanzadas, técnicas de ensamble, balanceo de clases y modelos de visión basados en Transformers para incrementar aún más el rendimiento obtenido.

XII. BIBLIOGRAFÍA

[1] T. N. Le and Q. V. Nguyen, “Garbage Classification Dataset,” Kaggle, 2024.

[2] M. Tan and Q. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks,” ICML, 2019.

[3] I. Goodfellow, Y. Bengio and A. Courville, Deep Learning, MIT Press, 2016.

[4] F. Chollet, Deep Learning with Python, Manning Publications, 2021.

[5] TensorFlow Team, TensorFlow Documentation, <https://www.tensorflow.org>